

MODUL MACHINE LEARNING



(KODE MK)

MODUL SESI 3

ALGORITMA DALAM SUPERVISED LEARNING

DISUSUN OLEH

Dr. VITRI TUNDJUNGSARI, S.T., M.Sc, M.M.

UNIVERSITAS ESA UNGGUL

2023

INTRODUCTION

1. Kemampuan Akhir Yang Diharapkan

Setelah mempelajari modul ini, diharapkan mahasiswa mampu :

- menjelaskan konsep dasar dan aplikasi Machine Learning (ML)
- menjelaskan cara kerja algoritma ML
- mengimplementasikan data yang diproses dengan ML
- mengidentifikasi tantangan dan potensi implementasi ML

2. Uraian dan Contoh

1. Visi dan Misi

Universitas Esa Unggul mempunyai visi menjadi perguruan tinggi kelas dunia berbasis intelektualitas, kreatifitas dan kewirausahaan, yang unggul dalam mutu pengelolaan dan hasil pelaksanaan Tridarma Perguruan Tinggi.

Untuk mewujudkan visi tersebut, maka Universitas Esa Unggul menetapkan misi-misi sebagai berikut :

- a) Menyelenggarakan pendidikan tinggi yang bermutu dan relevan
- b) Menciptakan suasana akademik yang kondusif
- c) Memberikan pelayanan prima kepada seluruh pemangku kepentingan

Tujuan dari dilaksanakannya misi-misi tersebut adalah:

- 1) Sumber daya manusia yang berkarakter dan berdaya saing tinggi.
- 2) Pengembangan ilmu pengetahuan, teknologi dan seni, serta kesejahteraan umat manusia.
- 3) Perguruan tinggi yang sehat dan mandiri. d
- 4) Perguruan tinggi yang bereputasi unggul.

2. Topik Perkuliahan

Pembahasan dalam matakuliah ini dimulai dengan pengenalan Machine Learning (ML) yang memiliki dua prinsip kerja, yaitu: Supervised dan Unsupervised Learning. Supervised learning merupakan pembelajaran yang memberi pelabelan terhadap data, training, dan tes sehingga dapat melakukan prediksi atau klasifikasi untuk data yang baru. Sedangkan

unsupervised learning tidak melakukan pelabelan data untuk melakukan prediksi atau klasifikasi. Pada modul ini dibahas mengenai beberapa algoritma yang digunakan dalam Supervised dan Unsupervised Learning. Selain itu, dalam modul ini juga diberikan contoh kasus untuk memberikan ilustrasi bagaimana algoritma dalam Supervised dan Unsupervised Learning bekerja. Kasus-kasus tersebut diselesaikan dengan Machine Learning menggunakan Bahasa Python. Pada bagian akhir dari modul ini dibahas tentang masalah dan tantangan yang dihadapi dalam Machine Learning.

Berikut ini topik-topik perkuliahan yang diberikan sebelum UTS:

Topik 1 – Pengenalan ML

Topik 2 – Supervised Learning vs Unsupervised Learning

Topik 3 – Algoritma Supervised Learning

Topik 4 – Algoritma Unsupervised Learning

Topik 5 -- Supervised Learning: Classification dan Regresi

Topik 6 – Supervised Learning: Decision Tree (DT)

Topik 7 – Supervised ML algorithm: Support Vector Machine (SVM)

Sedangkan topik-topik perkuliahan yang diberikan sebelum UAS adalah :

Topik 8 – Supervised Learning: Neural Network (Deep Learning)

Topik 9 – Supervised Learning: k-Nearest Neighbor

Topik 10 – Unsupervised Learning: Clustering

Topik 11 - Unsupervised Learning: Principal Component Analysis

Topik 12 – Fitur Representasi dan Rekayasa Data

Topik 13 – Evaluasi dan Perbaikan Model

Topik 14 – Tantangan dalam ML

3. Referensi dan Komponen Penilaian

Mata kuliah Machine Learning menggunakan beberapa referensi, yaitu:

1. Andreas Muller dan Sarah Guido, 2016. Introduction to Machine Learning with Python A Guide for Data Scientists: First edition.
2. Jan Wira Gotama Putra, 2020. Pengenalan Konsep dan pembelajaran Mesin dan Deep Learning, 2020: Edisi empat.

3. <https://databasetown.com/>

Untuk penilaian akhir, komponen nilai yang digunakan terdiri dari kehadiran, UTS, UAS dan penugasan. Dalam kuliah *online* komponen penugasan ditambah dengan kuis, sedangkan komponen kehadiran tidak diperhitungkan karena ditekankan pada aspek aktivitas di *website*. Adapun proporsi penilaiannya sebagai berikut :

- a. UTS = 25 %
- b. UAS = 30 %
- c. Kuis = 10 %
- d. Tugas = 35 %

SUPERVISED LEARNING

Seperti yang telah disebutkan dalam bab sebelumnya, Supervised Learning ML adalah salah satu jenis pembelajaran mesin yang paling sukses dan umum digunakan. Pada bab ini, kami akan menjelaskan *Supervised Learning* secara lebih rinci dan menjelaskan beberapa algoritma *Supervised Learning* yang populer.

Supervised Learning digunakan setiap kali kita ingin memprediksi hasil tertentu dari input yang diberikan, dan kita memiliki contoh pasangan input/output. Kita membangun model pembelajaran mesin dari pasangan input/output ini, yang terdiri dari set pelatihan kita. Tujuannya adalah membuat prediksi yang akurat untuk data baru yang belum pernah dilihat sebelumnya. Pembelajaran *Supervised Learning* sering kali membutuhkan upaya manusia untuk membangun set pelatihan, tetapi setelah itu mengotomatisasikan sehingga dapat mempercepat penyelesaian tugas.

Pada dasarnya, pembelajaran mesin menggunakan algoritma terprogram yang mempelajari dan mengoptimalkan operasinya dengan menganalisis data masukan untuk membuat prediksi dalam rentang yang dapat diterima. Algoritma ini cenderung membuat prediksi yang lebih akurat. Meski ada beberapa variasi caranya. Algoritma pembelajaran mesin kelompok dapat dibagi menjadi tiga kategori besar sesuai dengan tujuannya, yaitu: *Supervised Learning*, *Unsupervised Learning*, *Semisupervised Learning*.


Dalam algoritma *Supervised Learning* dataset pelatihan diberi label terlebih dahulu untuk melatih algoritma yang mendasarinya. Algoritma terlatih ini kemudian dimasukkan ke dalam kumpulan data pengujian yang tidak berlabel untuk mengkategorikannya ke dalam kumpulan data serupa

Kasus berikut mengilustrasikan bagaimana *Supervised Learning* bekerja. Terdapat data untuk tiga pasien diabetes, Gambar 1 menunjukkan ilustrasi tentang bagaimana *Supervised Learning* bekerja untuk mengkategorikan diabetes dan pasien non-diabetes. Algoritma *Supervised Learning* dapat diselesaikan dengan *Classification*/klasifikasi dan *Regression*/regresi. Dalam klasifikasi, variabel keluaran yang mendasarinya adalah diskrit, misalnya: variabel dikategorikan ke dalam kelompok atau kategori yang berbeda, seperti 'merah' atau 'hitam', atau bisa juga 'diabetes' dan 'nondiabetes'. Sedangkan untuk Regresi, variabel keluaran yang bersesuaian adalah nilai seperti risiko pengembangan penyakit kardiovaskular bagi seorang individu.

Pada bagian berikut akan dijelaskan beberapa metode terkait *Supervised Learning*, seperti: Regresi logistik (LR), *Support Vector Machine* (SVM), dan *Decision Tree* (DT).

1. Regresi logistic.


Regresi logistik (LR) adalah metode yang kuat dan mapan untuk *Supervised Learning*. Ini dapat dianggap sebagai perpanjangan dari regresi biasa dan hanya dapat memodelkan variabel dikotomis yang biasanya mewakili terjadinya atau tidak terjadinya suatu peristiwa. LR membantu dalam menemukan probabilitas bahwa sebuah *instance* baru termasuk dalam kelas tertentu. Karena ini adalah probabilitas, maka hasilnya terletak di antara 0 dan 1. Oleh karena itu, untuk menggunakan LR sebagai pengklasifikasi biner, ambang batas perlu ditetapkan untuk membedakan kelas keduanya. Misalnya, nilai probabilitas lebih tinggi dari 0,50 untuk instance masukan akan mengklasifikasikannya sebagai 'kelas A'; jika tidak, 'kelas B'. Model LR dapat digeneralisasikan untuk memodelkan variabel kategori dengan lebih dari dua nilai-nilai. Versi umum LR ini dikenal sebagai regresi logistik multinomial.



<https://www.analyticsvidhya.com/blog/2021/08/conceptual-understanding-of-logistic-regression-for-data-science-beginners/>

2. Support Vector Machine (SVM)

Algoritma *Support Vector Machine* (SVM) dapat mengklasifikasikan baik data linier maupun nonlinier. Langkah awalnya adalah memetakan masing-masing item data ke dalam ruang fitur n -dimensi, dengan n adalah jumlah fitur. Kemudian mengidentifikasi *hyperplane* yang memisahkan item data menjadi dua kelas sambil memaksimalkan jarak marjinal untuk kedua kelas dan meminimalkan kesalahan klasifikasi. Jarak marjinal suatu kelas adalah jarak antara *hyperplane* keputusan dan *instance* terdekat yang merupakan anggota kelas tersebut. Secara formal, setiap titik data diplot terlebih dahulu sebagai titik masuk ruang berdimensi n (di mana n adalah jumlah fitur) dengan nilai setiap fitur menjadi nilainya dari koordinat tertentu. Untuk melakukan klasifikasi, kemudian perlu mencari *hyperplane* yang membedakan kedua kelas dengan margin maksimum. Gambar 2 memberikan ilustrasi sederhana tentang pengklasifikasi SVM.




<https://www.analyticsvidhya.com/blog/2021/10/support-vector-machinessvm-a-complete-guide-for-beginners/>

3. *Decision Tree*

Decision Tree (DT) adalah salah satu algoritma ML yang paling awal dan menonjol. DT memodelkan logika keputusan yaitu, menguji dan mencocokkan hasil untuk mengklasifikasikan item data menjadi seperti pohon struktur. Node pada pohon DT biasanya mempunyai beberapa level dimana node pertama atau paling atas dipanggil simpul akar. Semua node internal (yaitu, node yang memiliki setidaknya satu anak) mewakili tes pada variabel input atau atribut. Tergantung pada hasil tes, algoritma klasifikasi bercabang menuju node anak yang sesuai tempat proses pengujian dan percabangan berulang hingga mencapai simpul daun. Daun atau simpul terminal berhubungan dengan keputusan hasil. DT ditemukan mudah untuk ditafsirkan dan cepat dipelajari, dan merupakan komponen yang umum banyak protokol diagnostik medis. Saat melintasi pohon untuk klasifikasi sampel, hasil dari semua pengujian pada setiap node di sepanjang jalur akan

memberikan informasi yang cukup untuk menduga tentang hal itu. Ilustrasi DT dengan unsur-unsur dan aturannya digambarkan pada Gambar 3.




<https://www.analyticsvidhya.com/blog/2021/08/decision-tree-algorithm/>

4. Random Forest (RF)

RF adalah pengklasifikasi ansambel dan terdiri dari banyak DT, sehingga dikatakan mirip dengan hutan yang terdiri dari sekumpulan banyak pohon. RF merupakan DT yang tumbuh sangat dalam, sehingga seringkali menyebabkan *overfitting* pada data pelatihan, sehingga menghasilkan variasi klasifikasi yang tinggi dan menghasilkan perubahan kecil pada data masukan. RF sangat sensitif terhadap data pelatihan, yang membuatnya rentan terhadap kesalahan pada kumpulan data pengujian. Yang membedakan RF dari DT adalah menggunakan bagian yang berbeda dari kumpulan data pelatihan. Untuk mengklasifikasikan sampel baru, vektor masukan dari sampel itu diperlukan untuk diturunkan dengan setiap kelompok DT dalam RF. Setiap DT kemudian mempertimbangkan bagian berbeda dari vektor masukan tersebut dan memberikan hasil klasifikasi. RF kemudian memilih klasifikasi yang mempunyai 'suara' terbanyak (untuk diskrit hasil klasifikasi) atau rata-rata seluruh pohon di hutan (untuk hasil klasifikasi numerik). Algoritma RF mempertimbangkan hasil dari banyak DT yang berbeda, sehingga dapat mengurangi varians yang dihasilkan dari

pertimbangan DT tunggal untuk himpunan data yang sama. Gambar 4 mengilustrasikan bagaimana algoritma RF bekerja.

EXAMPLES



<https://www.datacamp.com/>

5. Naïve Bayes

NB adalah teknik klasifikasi berdasarkan teorema Bayes. Teorema ini dapat menggambarkan kemungkinan suatu kejadian berdasarkan pengetahuan sebelumnya dan kondisi yang berkaitan dengan peristiwa itu. Pengklasifikasi ini mengasumsikan bahwa fitur tertentu dalam suatu kelas tidak berhubungan langsung ke fitur lain meskipun fitur untuk kelas itu memiliki saling ketergantungan di antara mereka sendiri. Gambar 5 memberikan ilustrasi tentang bagaimana teknik NB bekerja.

Weather	Play
Sunny	No
Overcast	Yes
Rainy	Yes
Sunny	Yes
Sunny	Yes
Overcast	Yes
Rainy	No
Rainy	No
Sunny	Yes
Rainy	Yes
Sunny	No
Overcast	Yes
Overcast	Yes
Rainy	No


Frequency Table		
Weather	No	Yes
Overcast		4
Rainy	3	2
Sunny	2	3
Grand Total	5	9

Likelihood table		
Weather	No	Yes
Overcast		4
Rainy	3	2
Sunny	2	3
All	5	9
	$\frac{5}{14}$	$\frac{9}{14}$
	0.36	0.64

<https://www.analyticsvidhya.com/blog/2017/09/naive-bayes-explained/>

6. *K-nearest neighbour* (KNN)

Algoritma KNN adalah salah satunya algoritma klasifikasi paling sederhana dan paling awal. KNN bisa dianggap sebagai versi sederhana dari pengklasifikasi NB. Berbeda dengan teknik NB, algoritma KNN tidak memerlukan untuk mempertimbangkan nilai probabilitas. KNN adalah algoritma yang mempertimbangkan sejumlah 'K' tetangga terdekat yang dipertimbangkan untuk mengambil 'suara' dari. Pemilihan nilai yang berbeda untuk 'K' dapat menghasilkan hasil klasifikasi yang berbeda untuk objek sampel yang sama.




<https://www.analyticsvidhya.com/blog/2018/03/introduction-k-neighbours-algorithm-clustering/>

7. Jaringan saraf tiruan (JST)

Jaringan saraf tiruan (JST) adalah sekumpulan algoritma pembelajaran mesin yang terinspirasi oleh berfungsinya jaringan saraf otak manusia. JST pertama kali diusulkan oleh McCulloch dan Pitts [30] dan kemudian dipopulerkan oleh Rumelhart dkk pada tahun 1980an [31]. Pada otak biologis, neuron terhubung satu sama lain melalui banyak hal persimpangan akson membentuk grafik seperti arsitektur. Interkoneksi ini dapat dihubungkan kembali (misalnya melalui neuroplastisitas) yang membantu beradaptasi, memproses, dan menyimpan informasi. Demikian pula, algoritma ANN dapat direpresentasikan sebagai sekelompok node yang

saling berhubungan. Output dari satu node digunakan sebagai input ke node lain, dan pemrosesan selanjutnya dilakukan sesuai interkoneksi. Node biasanya dikelompokkan ke dalam matriks yang disebut lapisan tergantung pada transformasi yang mereka lakukan.

Selain lapisan masukan dan keluaran, mungkin ada satu atau lebih lapisan tersembunyi dalam kerangka JST. Node dan tepian memiliki bobot yang memungkinkan untuk disesuaikan untuk memberi sinyal kekuatan komunikasi yang dapat diperkuat atau dilemahkan melalui pelatihan berulang. Berdasarkan pelatihan dan adaptasi selanjutnya dari matriks, bobot simpul dan tepi, JST dapat membuat prediksi untuk data pengujian. Gambar 7 menunjukkan ilustrasi JST (dengan dua lapisan tersembunyi) dengan kelompok node yang saling berhubungan.



https://ml-lectures.org/docs/supervised_learning_w_NNs/ml_supervised_w_NNs.html

Daftar Pustaka

1. Andreas Muller dan Sarah Guido, 2016. Introduction to Machine Learning with Python A Guide for Data Scientists: First edition.
2. Jan Wira Gotama Putra, 2020. Pengenalan Konsep dan pembelajaran Mesin dan Deep Learning, 2020: Edisi empat.
3. <https://databasetown.com/>