

MODUL MACHINE LEARNING



(KODE MK)

MODUL SESI 5

SUPERVISED LEARNING: KLASIFIKASI DAN REGRESI

DISUSUN OLEH

Dr. VITRI TUNDJUNGSARI, S.T., M.Sc, M.M.

UNIVERSITAS ESA UNGGUL

2023

INTRODUCTION

1. Kemampuan Akhir Yang Diharapkan

Setelah mempelajari modul ini, diharapkan mahasiswa mampu :

- menjelaskan konsep dasar dan aplikasi Machine Learning (ML)
- menjelaskan cara kerja algoritma ML
- mengimplementasikan data yang diproses dengan ML
- mengidentifikasi tantangan dan potensi implementasi ML

2. Uraian dan Contoh

1. Visi dan Misi

Universitas Esa Unggul mempunyai visi menjadi perguruan tinggi kelas dunia berbasis intelektualitas, kreatifitas dan kewirausahaan, yang unggul dalam mutu pengelolaan dan hasil pelaksanaan Tridarma Perguruan Tinggi.

Untuk mewujudkan visi tersebut, maka Universitas Esa Unggul menetapkan misi-misi sebagai berikut :

- a) Menyelenggarakan pendidikan tinggi yang bermutu dan relevan
- b) Menciptakan suasana akademik yang kondusif
- c) Memberikan pelayanan prima kepada seluruh pemangku kepentingan

Tujuan dari dilaksanakannya misi-misi tersebut adalah:

- 1) Sumber daya manusia yang berkarakter dan berdaya saing tinggi.
- 2) Pengembangan ilmu pengetahuan, teknologi dan seni, serta kesejahteraan umat manusia.
- 3) Perguruan tinggi yang sehat dan mandiri. d
- 4) Perguruan tinggi yang bereputasi unggul.

2. Topik Perkuliahan

Pembahasan dalam matakuliah ini dimulai dengan pengenalan Machine Learning (ML) yang memiliki dua prinsip kerja, yaitu: Supervised dan Unsupervised Learning. Supervised learning merupakan pembelajaran yang memberi pelabelan terhadap data, training, dan tes sehingga dapat melakukan prediksi atau klasifikasi untuk data yang baru. Sedangkan unsupervised learning tidak melakukan pelabelan data untuk melakukan

prediksi atau klasifikasi. Pada modul ini dibahas mengenai beberapa algoritma yang digunakan dalam Supervised dan Unsupervised Learning. Selain itu, dalam modul ini juga diberikan contoh kasus untuk memberikan ilustrasi bagaimana algoritma dalam Supervised dan Unsupervised Learning bekerja. Kasus-kasus tersebut diselesaikan dengan Machine Learning menggunakan Bahasa Python. Pada bagian akhir dari modul ini dibahas tentang masalah dan tantangan yang dihadapi dalam Machine Learning.

Berikut ini topik-topik perkuliahan yang diberikan sebelum UTS:

Topik 1 – Pengenalan ML

Topik 2 – Supervised Learning vs Unsupervised Learning

Topik 3 – Algoritma Supervised Learning

Topik 4 – Algoritma Unsupervised Learning

Topik 5 -- Supervised Learning: Classification dan Regresi

Topik 6 – Supervised Learning: Decision Tree (DT)

Topik 7 – Supervised ML algorithm: Support Vector Machine (SVM)

Sedangkan topik-topik perkuliahan yang diberikan sebelum UAS adalah :

Topik 8 – Supervised Learning: Neural Network (Deep Learning)

Topik 9 – Supervised Learning: k-Nearest Neighbor

Topik 10 – Unsupervised Learning: Clustering

Topik 11 - Unsupervised Learning: Principal Component Analysis

Topik 12 – Fitur Representasi dan Rekayasa Data

Topik 13 – Evaluasi dan Perbaikan Model

Topik 14 – Tantangan dalam ML

3. Referensi dan Komponen Penilaian

Mata kuliah Machine Learning menggunakan beberapa referensi, yaitu:

1. Andreas Muller dan Sarah Guido, 2016. Introduction to Machine Learning with Python A Guide for Data Scientists: First edition.
2. Jan Wira Gotama Putra, 2020. Pengenalan Konsep dan *machine learning* dan Deep Learning, 2020: Edisi empat.
3. <https://databasetown.com/>

Untuk penilaian akhir, komponen nilai yang digunakan terdiri dari kehadiran, UTS, UAS dan penugasan. Dalam kuliah *online* komponen penugasan ditambah dengan kuis, sedangkan komponen kehadiran tidak diperhitungkan karena ditekankan pada aspek aktivitas di *website*. Adapun proporsi penilaiannya sebagai berikut :

- a. UTS = 25 %
- b. UAS = 30 %
- c. Kuis = 10 %
- d. Tugas = 35 %


SUPERVISED LEARNING: KLASIFIKASI DAN REGRESI

Ada dua jenis utama masalah *supervised learning*, yang disebut klasifikasi dan *regresi*. Dalam klasifikasi, tujuannya adalah untuk memprediksi *label kelas*, yang merupakan pilihan dari daftar kemungkinan yang sudah ditentukan.

KLASIFIKASI

Pada bab ini, kami menggunakan contoh untuk mengklasifikasikan bunga iris ke dalam salah satu dari tiga spesies yang mungkin. Klasifikasi terkadang dipisahkan menjadi *klasifikasi biner*, yang merupakan kasus khusus untuk membedakan antara dua kelas, dan *klasifikasi multikelas*, yang merupakan klasifikasi antara lebih dari dua kelas. Contoh iris mata adalah contoh dari probabilitas klasifikasi multikelas.


Dalam klasifikasi biner, kita sering berbicara tentang satu kelas sebagai kelas *positif* dan kelas lainnya sebagai kelas *negatif*. Di sini, positif tidak berarti memiliki manfaat atau nilai, tetapi lebih kepada apa yang menjadi objek penelitian. Jadi, ketika mencari spam, "positif" bisa berarti kelas spam. Yang mana dari dua kelas yang disebut positif sering kali merupakan masalah subjektif, dan spesifik untuk domain. Anda bisa menganggap klasifikasi biner sebagai mencoba menjawab pertanyaan ya/tidak.



Contoh klasifikasi biner

Contoh lain adalah, mengklasifikasikan email sebagai spam atau bukan spam adalah contoh masalah klasifikasi biner. Dalam tugas klasifikasi biner ini, pertanyaan ya/tidak yang ditanyakan adalah "Apakah email ini spam?"


Contoh lainnya adalah memprediksi bahasa apa yang digunakan sebuah situs web dari teks di situs web tersebut. Kelas-kelas di sini adalah daftar bahasa yang telah ditentukan sebelumnya.



Contoh klasifikasi email untuk inbox dan spam folder

REGRESI

Untuk tugas regresi, tujuannya adalah untuk memprediksi angka kontinu, atau *angka floating-point* dalam istilah pemrograman (atau *angka riil dalam* istilah matematika). Memprediksi pendapatan tahunan seseorang dari pendidikan, usia, dan tempat tinggalnya adalah contoh tugas regresi. Ketika memprediksi pendapatan, nilai yang diprediksi adalah sebuah angka, dan dapat berupa angka apa pun dalam rentang tertentu. Contoh lain dari tugas regresi adalah memprediksi hasil panen sebuah ladang jagung dengan atribut seperti hasil panen sebelumnya, cuaca, dan jumlah karyawan yang bekerja di ladang tersebut. Hasil panen dapat berupa angka sembarang.



Contoh regresi linear

KLASIFIKASI atau REGRESI?

Cara mudah untuk membedakan antara tugas klasifikasi dan regresi adalah dengan menanyakan apakah ada kesinambungan pada keluarannya. Jika ada kesinambungan antara hasil yang mungkin, maka masalahnya adalah masalah

regresi. Pikirkan tentang memprediksi pendapatan tahunan. Misalnya, apakah seseorang membuat Rp 4 milyar atau Rp 4,01 Milyar per tahun tidak membuat perbedaan yang nyata, meskipun ini adalah jumlah uang yang berbeda. Sehingga, jika algoritma kami memprediksi Rp 3,99 milyar atau Rp 4,01 milyar ketika seharusnya memprediksi Rp 4 milyar, kami tidak terlalu mempermasalahkannya.

Sebaliknya, untuk tugas mengenali bahasa situs web (yang merupakan masalah klasifikasi), harus ditentukan secara tepat. Misalnya, sebuah email harus mampu mengklasifikasikan apakah email tersebut spam atau bukan secara tegas.


CONTOH KASUS: Klasifikasi Spesies Iris

Pada bagian ini, kita akan membahas aplikasi ML sederhana dan membuat model pertama kita. Dalam prosesnya, kami akan memperkenalkan beberapa konsep dan istilah inti.

Misal sebuah kasus, seorang ahli botani yang tertarik untuk membedakan spesies beberapa bunga iris yang ditemukannya. Ia telah mengumpulkan beberapa ukuran yang terkait dengan masing-masing iris, yaitu: (1) panjang dan lebar kelopak bunga; (2) panjang dan lebar sepal, semuanya diukur dalam sentimeter (lihat **Gambar 1-2**).; (3) Ahli botani tersebut juga memiliki pengukuran beberapa iris yang sebelumnya telah diidentifikasi oleh ahli botani sebagai bagian dari spesies *setosa*, *versicolor*, atau *virginica*.

Dengan pengukuran ini, ia bisa memastikan spesies mana yang dimiliki oleh setiap iris.

Tujuan ML untuk kasus ini adalah membangun model pembelajaran mesin yang dapat belajar dari pengukuran iris mata yang telah diketahui spesiesnya, sehingga kami dapat memprediksi spesies untuk iris mata yang baru.



Gambar 1-2. Bagian-bagian bunga iris

Karena kita memiliki pengukuran yang kita ketahui spesies iris yang benar, ini adalah masalah pembelajaran yang diawasi. Dalam masalah ini, kita ingin memprediksi salah satu dari beberapa pilihan (spesies iris). Ini adalah contoh masalah *klasifikasi*. Hasil yang mungkin (spesies iris yang berbeda) disebut *kelas*. Setiap iris dalam dataset termasuk ke dalam salah satu dari tiga kelas, jadi masalah ini adalah masalah klasifikasi tiga kelas. Keluaran yang diinginkan untuk satu titik data (iris) adalah spesies bunga ini. Untuk titik data tertentu, spesies yang dimilikinya disebut labelnya.

Dataset Iris

Data yang akan kita gunakan untuk contoh ini adalah dataset Iris, sebuah dataset klasik dalam pembelajaran mesin dan statistik. Dataset ini disertakan dalam scikit-learn dalam modul dataset. Kita dapat memuatnya dengan memanggil fungsi `load_iris`, sebagaimana berikut.

In [10]:

```
from sklearn.datasets import load_iris iris_dataset = load_iris()
```

Objek `iris` yang dikembalikan oleh `load_iris` adalah objek `Bunch`, yang sangat mirip dengan kamus. Objek ini berisi kunci dan nilai:

In [11]:

```
print("Keys of iris_dataset: \n{}".format(iris_dataset.keys()))
```

Out[11]:

Keys of iris_dataset:

```
dict_keys(['target_names', 'feature_names', 'DESCR', 'data', 'target'])
```

Nilai dari kunci DESCR adalah deskripsi singkat dari set data. Kami menampilkan bagian awal deskripsi di sini (silakan cari sendiri sisanya):

In [12]:

```
print(iris_dataset['DESCR'][:193] + "\n...")
```

Out[12]:

Iris Plants Database

=====

Notes

Data Set Characteristics:

:Number of Instances: 150 (50 in each of three classes)

:Number of Attributes: 4 numeric, predictive att

...

Nilai dari key target_names adalah sebuah array string, berisi spesies bunga yang ingin kita prediksi:

In [13]:

```
print("Target names: {}".format(iris_dataset['target_names']))
```

Out[13]:

Target names: ['setosa' 'versicolor' 'virginica']

Nilai dari nama_fitur adalah daftar string, yang memberikan deskripsi setiap fitur:

In [14]:

```
print("Feature names: \n{}".format(iris_dataset['feature_names']))
```

Out[14]:

Feature names:

['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)',

'petal width (cm)']

In [15]:

```
print("Type of data: {}".format(type(iris_dataset['data']))) Out[15]:  
Type of data: <class 'numpy.ndarray'>
```

Baris dalam larik data sesuai dengan bunga, sedangkan kolom mewakili empat pengukuran yang dilakukan untuk setiap bunga:

In [16]:

```
print("Shape of data: {}".format(iris_dataset['data'].shape)) Out[16]:  
Shape of data: (150, 4)
```

Kita melihat bahwa larik tersebut berisi pengukuran untuk 150 bunga yang berbeda. Ingatlah bahwa setiap item disebut *sampel* dalam pembelajaran mesin, dan propertinya disebut *fitur*. Bentuk larik data adalah jumlah sampel dikalikan dengan jumlah fitur. Ini adalah konvensi dalam scikit-learn, dan data Anda akan selalu diasumsikan berbentuk seperti ini. Berikut adalah nilai fitur untuk lima sampel pertama:

In [17]:

```
print("First five columns of data:\n{}".format(iris_dataset['data'][:5]))  
Out[17]:
```

First five columns of data:

```
[[ 5.1  3.5  1.4  0.2]  
 [ 4.9  3.   1.4  0.2]  
 [ 4.7  3.2  1.3  0.2]  
 [ 4.6  3.1  1.5  0.2]  
 [ 5.   3.6  1.4  0.2]]
```

Dari data ini, kita dapat melihat bahwa kelima bunga pertama memiliki lebar kelopak 0,2 cm dan bunga pertama memiliki sepal terpanjang, yaitu 5,1 cm.

Larik target berisi spesies masing-masing bunga yang diukur, juga sebagai larik NumPy:

In [18]:

```
print("Type of target: {}".format(type(iris_dataset['target']))) Out[18]:  
Type of target: <class 'numpy.ndarray'>
```

In [19]:

```
print("Shape of target: {}".format(iris_dataset['target'].shape)) Out[19]:
```

Shape of target: (150,)

The species are encoded as integers from 0 to 2:

In [20]:

```
print("Target:\n{}".format(iris_dataset['target'])) Out[20]:
```

Target:

```
[000000000000000000000000000000000000000000000  
0000000000000111111111111111111111111111111111  
11111111111111111111111112222222222222222222222  
2222222222222222222222222222222222222222]
```

Arti angka diberikan oleh larik iris["target_names"]: 0 berarti *setosa*, 1 berarti *versicolor*, dan 2 berarti *virginica*.

Mengukur Keberhasilan: Data Pelatihan dan Pengujian

Kami ingin membangun model pembelajaran mesin dari data ini yang dapat memprediksi spesifikasi iris mata untuk serangkaian pengukuran baru. Tetapi sebelum kita dapat menerapkan model kita pada pengukuran baru, kita perlu mengetahui apakah model tersebut benar-benar berfungsi-yaitu, apakah kita harus mempercayai prediksinya.

Sayangnya, kita tidak dapat menggunakan data yang kita gunakan untuk membangun model untuk mengevaluasinya. Hal ini dikarenakan model kita selalu dapat mengingat seluruh data pelatihan, dan oleh karena itu akan selalu memprediksi label yang benar untuk setiap titik dalam data pelatihan. "Mengingat" ini tidak menunjukkan kepada kita apakah model kita akan *menggeneralisasi dengan baik* (dengan kata lain, apakah model tersebut juga akan berkinerja baik pada data baru).

Untuk menilai kinerja model, kami menunjukkan data baru (data yang belum pernah dilihat sebelumnya) yang telah diberi label. Hal ini biasanya dilakukan dengan membagi data berlabel yang telah kita kumpulkan (di sini, 150 pengukuran bunga) menjadi dua bagian. Satu bagian dari data

digunakan untuk membangun model pembelajaran mesin kita, dan disebut *data pelatihan* atau *training set*. Sisa data lainnya akan digunakan untuk menilai seberapa baik model tersebut bekerja; ini disebut *data uji*, *set uji*, atau *set uji coba*.

Scikit-learn berisi sebuah fungsi yang mengacak dataset dan membaginya untuk Anda: fungsi `train_test_split`. Fungsi ini mengekstrak 75% dari baris dalam data sebagai himpunan pelatihan, bersama dengan label yang sesuai untuk data ini. Sisa 25% dari data, bersama dengan label yang tersisa, dinyatakan sebagai set uji. Memutuskan berapa banyak data yang ingin Anda masukkan ke dalam set pelatihan dan set pengujian masing-masing adalah beberapa-apa yang sewenang-wenang, tetapi menggunakan set pengujian yang berisi 25% data adalah aturan praktis yang baik.

Dalam scikit-learn, data biasanya dilambangkan dengan huruf besar X , sedangkan label dilambangkan dengan huruf kecil y . Hal ini terinspirasi dari formulasi standar $f(x)=y$ dalam matematika, di mana x adalah input ke sebuah fungsi dan y adalah output. Mengikuti lebih banyak konvensi dari matematika, kami menggunakan huruf kapital X karena datanya berupa larik dua dimensi (matriks) dan huruf kecil y karena targetnya berupa larik satu dimensi (vektor).

Selanjutnya kita panggil `train_test_split` pada data kita dan tetapkan output menggunakan nomenklatur ini:

In [21]:

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    iris_dataset['data'], iris_dataset['target'], random_state=0)
```

Sebelum melakukan pemisahan, fungsi `train_test_split` mengacak dataset menggunakan generator angka pseudorandom. Jika kita hanya mengambil 25% data terakhir sebagai set uji, semua titik data akan memiliki label 2, karena titik data diurutkan berdasarkan label (lihat output untuk `iris['target']` yang ditunjukkan sebelumnya). Menggunakan set

pengujian yang hanya berisi satu dari tiga kelas tidak akan memberi tahu kita banyak tentang seberapa baik model kita menggeneralisasi, jadi kita mengacak data kita untuk memastikan data pengujian berisi data dari semua kelas.

Untuk memastikan bahwa kita akan mendapatkan hasil yang sama jika kita menjalankan fungsi yang sama beberapa kali, kita memberikan pseudorandom number generator dengan seed yang tetap menggunakan parameter `random_state`. Hal ini akan membuat hasilnya menjadi deterministik, sehingga baris ini akan selalu memiliki hasil yang sama. Kita akan selalu memperbaiki `random_state` dengan cara ini ketika menggunakan prosedur-prosedur pengacakan dalam buku ini.

Keluaran dari fungsi `train_test_split` adalah `X_train`, `X_test`, `y_train`, dan `y_test`, yang semuanya merupakan larik NumPy. `X_train` berisi 75% dari baris dataset, dan `X_test` berisi 25% sisanya:

In [22]:

```
print("X_train shape: {}".format(X_train.shape)) print("y_train shape: {}".format(y_train.shape))
```

Out[22]:

X_train shape: (112, 4)

y_train shape: (112,)

In [23]:

```
print("X_test shape: {}".format(X_test.shape)) print("y_test shape: {}".format(y_test.shape))
```

Out[23]:

X_test shape: (38, 4)

y_test shape: (38,)

Memeriksa Data

Sebelum membangun model pembelajaran mesin, ada baiknya untuk memeriksa data, untuk melihat apakah tugas tersebut dapat diselesaikan dengan mudah tanpa pembelajaran mesin, atau apakah informasi yang diinginkan mungkin tidak terkandung dalam data.


Selain itu, memeriksa data Anda adalah cara yang baik untuk menemukan ketidaknormalan dan keanehan. Mungkin beberapa iris mata Anda diukur dengan menggunakan satuan inci dan bukan sentimeter, misalnya. Di dunia nyata, ketidakkonsistenan dalam data dan pengukuran yang tidak terduga adalah hal yang sangat umum.

Salah satu cara terbaik untuk memeriksa data adalah dengan memvisualisasikannya. Salah satu cara untuk melakukannya adalah dengan menggunakan *scatter plot*. Plot sebaran data menempatkan satu fitur di sepanjang sumbu x dan fitur lainnya di sepanjang sumbu y, dan menggambar titik untuk setiap titik data. Sayangnya, layar komputer hanya memiliki dua dimensi, yang memungkinkan kita untuk memplot hanya dua (atau mungkin tiga) fitur pada satu waktu. Sulit untuk memplot set data dengan lebih dari tiga fitur dengan cara ini. Salah satu cara untuk mengatasi masalah ini adalah dengan melakukan *plot pasangan*, yang melihat semua pasangan fitur yang mungkin. Jika Anda memiliki sejumlah kecil fitur, seperti empat fitur yang kami miliki di sini, hal ini cukup masuk akal. Namun, Anda harus ingat bahwa pair plot tidak menunjukkan interaksi dari semua fitur sekaligus, sehingga beberapa aspek menarik dari data mungkin tidak akan terlihat ketika memvisualisasikannya dengan cara ini.

Gambar 1-3 adalah plot pasangan fitur dalam set pelatihan. Titik-titik data diwarnai sesuai dengan spesies iris mata. Untuk membuat plot, pertama-tama kita mengonversi larik NumPy ke dalam DataFrame pandas. pandas memiliki fungsi untuk membuat plot pasangan yang disebut `scatter_matrix`. Diagonal dari matriks ini diisi dengan histogram dari setiap fitur:

In [24]:

```
# create dataframe from data in X_train
# label the columns using the strings in iris_dataset.feature_names
iris_dataframe = pd.DataFrame(X_train,
                              columns=iris_dataset.feature_names)
# create a scatter matrix from the dataframe, color by y_train
grr = pd.scatter_matrix(iris_dataframe, c=y_train, figsize=(15, 15),
                        marker='o', hist_kwds
                        ={'bins': 20}, s=60, alpha=.8, cmap=mglearn.cm3)
```



Gambar 1-3. Plot pasangan dari dataset Iris, diwarnai dengan label kelas

Dari plot tersebut, kita dapat melihat bahwa ketiga kelas tersebut tampaknya relatif terpisah dengan baik menggunakan pengukuran sepal dan kelopak. Ini berarti bahwa model pembelajaran mesin kemungkinan besar akan dapat belajar untuk memisahkannya.

Daftar Pustaka

1. Andreas Muller dan Sarah Guido, 2016. Introduction to Machine Learning with Python A Guide for Data Scientists: First edition.
2. Jan Wira Gotama Putra, 2020. Pengenalan Konsep dan *machine learning* dan Deep Learning, 2020: Edisi empat.
3. <https://databasetown.com/>