

TUGAS ULANGAN TENGAH SEMESTER



Dosen Pengampu:

Dr. Rahmat Budiarsa, S.Kom.

Disusun Oleh:

Ilham Firmansyah (20240801102)

Mata Kuliah:

Machine Learning (CR001)

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS ESA UNGGUL

2026

1. Menurut pemahaman Anda, secara garis besar machine learning dibagi kedalam berapa kategori, jelaskan setiap kategori dan jenis utama setiap kategori tersebut.

Jawab:

Machine Learning secara garis besar dibagi menjadi tiga kategori utama, yaitu Supervised Learning, Unsupervised Learning, dan Reinforcement Learning.

1. Supervised Learning

Supervised Learning adalah metode machine learning yang menggunakan data yang sudah memiliki label atau target. Pada metode ini, model dilatih menggunakan pasangan data input dan output sehingga model dapat memprediksi hasil dari data baru.

Tujuan utama supervised learning adalah melakukan prediksi atau klasifikasi berdasarkan pola yang dipelajari dari data latih.

Jenis utama dalam supervised learning yaitu:

- **Classification**, digunakan untuk memprediksi kategori tertentu, seperti email spam atau bukan spam.
- **Regression**, digunakan untuk memprediksi nilai numerik atau kontinu, seperti prediksi harga rumah atau pendapatan.

Contoh algoritma supervised learning:

- Decision Tree
- K-Nearest Neighbor (KNN)
- Support Vector Machine (SVM)
- Random Forest
- Logistic Regression

2. Unsupervised Learning

Unsupervised Learning adalah metode machine learning yang menggunakan data tanpa label. Model akan mencari pola, hubungan, atau struktur tersembunyi secara otomatis dari data.

Tujuan utama unsupervised learning adalah menemukan pola atau pengelompokan data.

Jenis utama dalam unsupervised learning yaitu:

- **Clustering**, digunakan untuk mengelompokkan data berdasarkan kemiripan karakteristik.
- **Association Rule Mining**, digunakan untuk mencari hubungan antar data.
- **Dimensionality Reduction**, digunakan untuk mengurangi jumlah fitur data tanpa menghilangkan informasi penting.

Contoh algoritma unsupervised learning:

- K-Means Clustering
- Hierarchical Clustering
- Principal Component Analysis (PCA)

3. Reinforcement Learning

Reinforcement Learning adalah metode machine learning yang melatih model untuk belajar melalui interaksi dengan lingkungan. Model akan menerima reward atau punishment berdasarkan tindakan yang dilakukan.

Tujuan reinforcement learning adalah membuat agen mampu mengambil keputusan terbaik berdasarkan pengalaman sebelumnya.

Contoh penerapan reinforcement learning:

- Robotika
- Game AI
- Mobil tanpa pengemudi
- Sistem rekomendasi adaptif

2. Jelaskan menurut pemahaman Anda, apa saja langkah-langkah dalam membuat suatu model machine learning, mulai dari pengumpulan data sampai uji coba dengan data baru (evaluasi uji coba).

Jawab:

1. Pengumpulan Data

Langkah pertama adalah mengumpulkan data yang sesuai dengan permasalahan yang ingin diselesaikan. Data dapat diperoleh dari database, website, survei, sensor, ataupun dataset publik.

Contohnya pada project kelompok kami menggunakan dataset Stack Overflow Developer Survey 2024 untuk menganalisis dan memprediksi penggunaan teknologi developer.

2. Data Cleaning dan Preprocessing

Setelah data dikumpulkan, dilakukan proses pembersihan data untuk mengatasi:

- data kosong (missing value),
- data duplikat,
- data tidak konsisten,
- dan data yang tidak relevan.

Selain itu dilakukan preprocessing seperti encoding, normalisasi, dan transformasi data agar data siap digunakan oleh algoritma machine learning.

3. Exploratory Data Analysis (EDA)

Pada tahap ini dilakukan analisis dan visualisasi data untuk memahami karakteristik dataset. Tujuannya adalah mengetahui pola, distribusi data, hubungan antar fitur, dan mendeteksi anomali pada data.

Visualisasi dapat dilakukan menggunakan:

- scatter plot,
- histogram,
- bar chart,
- heatmap,
- dan pie chart.

4. Pemilihan Fitur (Feature Selection)

Tahap selanjutnya adalah memilih fitur-fitur yang paling relevan terhadap target prediksi. Pemilihan fitur penting agar model lebih efektif, cepat, dan akurat.

5. Pembagian Data

Dataset kemudian dibagi menjadi:

- data training,
- dan data testing.

Biasanya pembagian dilakukan dengan rasio 80:20 atau 70:30. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk menguji performa model.

6. Pemilihan Algoritma Machine Learning

Pada tahap ini dipilih algoritma yang sesuai dengan jenis permasalahan.

Contohnya:

- Decision Tree,
- SVM,
- KNN,
- Random Forest,
- atau K-Means Clustering.

Pemilihan algoritma bergantung pada jenis data dan tujuan penelitian.

7. Training Model

Model machine learning dilatih menggunakan data training agar dapat mempelajari pola dan hubungan antar data.

Pada tahap ini algoritma akan membangun model berdasarkan dataset yang diberikan.

8. Evaluasi Model

Setelah model selesai dilatih, dilakukan evaluasi menggunakan data testing untuk mengetahui performa model.

Beberapa metode evaluasi yang dapat digunakan yaitu:

- Accuracy,
- Precision,
- Recall,
- F1-Score,
- Confusion Matrix,
- dan Silhouette Score untuk clustering.

9. Uji Coba dengan Data Baru

Tahap terakhir adalah menguji model menggunakan data baru yang belum pernah digunakan sebelumnya. Tujuannya adalah mengetahui apakah model mampu melakukan prediksi dengan baik pada kondisi nyata.

Jika hasil evaluasi belum optimal, maka model dapat diperbaiki kembali melalui tuning parameter, pemilihan fitur, ataupun pergantian algoritma.

LAPORAN PROPOSAL
ANALISIS DAN SEGMENTASI DEVELOPER SERTA PREDIKSI PENGGUNAAN
TEKNOLOGI MENGGUNAKAN MACHINE LEARNING
PADA DATASET STACK OVERFLOW



Dosen Pengampu:

Dr. Rahmat Budiarsa, S.Kom.

Disusun Oleh:

- Ilham Firmansyah (20240801102)
- Luqman Syahreno (20240801016)
- Siti Ahsanu Nadiyya Rizal (20240801155)
- Aidah Ruhiyah Ramadhani (20240801142)
- Muhammad Aditya (20240801234)

Mata Kuliah:

Machine Learning (CR001)

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS ESA UNGGUL
2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan internet saat ini menghasilkan data dalam jumlah yang sangat besar dan terus bertambah setiap harinya [1]. Salah satu bidang yang mengalami perkembangan pesat adalah dunia pengembangan perangkat lunak (software development). Developer di berbagai negara menggunakan beragam teknologi seperti bahasa pemrograman, framework, database, cloud platform, hingga Artificial Intelligence (AI) tools dalam proses pengembangan aplikasi dan sistem. Banyaknya variasi teknologi tersebut menghasilkan data yang kompleks dan menarik untuk dianalisis menggunakan Machine Learning [2].

Machine Learning merupakan salah satu cabang dari Artificial Intelligence (AI) yang memungkinkan komputer untuk mempelajari pola dari data dan membuat prediksi tanpa harus diprogram secara eksplisit. Machine Learning banyak digunakan dalam berbagai bidang karena mampu membantu proses analisis data, pengambilan keputusan, klasifikasi, prediksi, hingga segmentasi data secara otomatis dan efisien [3].

Dalam penelitian ini digunakan dataset Stack Overflow Developer Survey, yaitu dataset hasil survei tahunan yang dilakukan oleh Stack Overflow terhadap developer di berbagai negara. Dataset tersebut berisi berbagai informasi mengenai developer seperti pengalaman kerja, jenis pekerjaan, bahasa pemrograman yang digunakan, database, cloud platform, AI tools, serta teknologi lainnya yang digunakan dalam aktivitas pengembangan perangkat lunak. Dataset ini memiliki jumlah data yang besar dan fitur yang beragam sehingga sangat cocok digunakan untuk penelitian berbasis machine learning [4].

Penelitian ini berfokus pada analisis dan segmentasi developer serta prediksi penggunaan teknologi menggunakan metode machine learning. Pada proses segmentasi developer digunakan metode unsupervised learning yaitu K-Means Clustering untuk mengelompokkan developer berdasarkan karakteristik dan teknologi yang digunakan [5], [6]. Selain itu, penelitian ini juga menggunakan metode supervised learning yaitu Support Vector Machine (SVM) dan Random Forest untuk melakukan prediksi penggunaan teknologi berdasarkan data developer yang tersedia [7], [8], [9], [10].

Penggunaan metode clustering dapat membantu memahami pola dan karakteristik developer berdasarkan teknologi yang digunakan. Sedangkan metode klasifikasi dapat membantu memprediksi kecenderungan penggunaan teknologi tertentu oleh developer berdasarkan pengalaman, pekerjaan, dan atribut lainnya [5], [7]. Hasil penelitian ini diharapkan dapat

memberikan wawasan mengenai tren penggunaan teknologi di kalangan developer serta dapat menjadi referensi dalam pengembangan teknologi dan kebutuhan industri perangkat lunak di masa mendatang.

Berdasarkan latar belakang tersebut, penelitian ini mengangkat topik mengenai implementasi supervised learning dan unsupervised learning untuk analisis, segmentasi developer, dan prediksi penggunaan teknologi pada dataset Stack Overflow Developer Survey.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana melakukan analisis terhadap data developer pada dataset Stack Overflow Developer Survey?
2. Bagaimana mengelompokkan developer berdasarkan karakteristik dan teknologi yang digunakan menggunakan metode K-Means Clustering?
3. Bagaimana menerapkan metode Support Vector Machine (SVM) dan Random Forest dalam memprediksi penggunaan teknologi developer?
4. Bagaimana tingkat performa model machine learning yang digunakan dalam melakukan prediksi penggunaan teknologi berdasarkan data developer?

1.3 Batasan Masalah

Agar penelitian lebih terarah dan tidak menyimpang dari tujuan utama, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Dataset yang digunakan merupakan Stack Overflow Developer Survey tahun 2024 dan 2025.
2. Penelitian hanya menggunakan beberapa fitur yang berkaitan dengan karakteristik developer dan penggunaan teknologi.
3. Metode unsupervised learning yang digunakan adalah K-Means Clustering.
4. Metode supervised learning yang digunakan adalah Support Vector Machine (SVM) dan Random Forest.
5. Penelitian difokuskan pada analisis, segmentasi developer, dan prediksi penggunaan teknologi tertentu.
6. Implementasi machine learning dilakukan menggunakan bahasa pemrograman Python dengan bantuan Visual Studio Code (VS Code).

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis data developer pada dataset Stack Overflow Developer Survey.
2. Mengelompokkan developer berdasarkan karakteristik dan penggunaan teknologi menggunakan metode K-Means Clustering.
3. Menerapkan metode Support Vector Machine (SVM) dan Random Forest untuk memprediksi penggunaan teknologi developer.
4. Mengetahui performa model machine learning dalam melakukan prediksi penggunaan teknologi berdasarkan data developer.

DAFTAR PUSTAKA

- [1] E. Brezovec, M. Zelić, and A. M. Zagode, “Stabilizing truth in educational sciences: a systematic review of generative AI in education,” *Kybernetes*, vol. 55, no. 13, pp. 1–17, 2026, doi: 10.1108/K-09-2025-2339.
- [2] M. Béréte, A. Ehtioui, L. Sellami, and A. A. Ben Hmida, “Hybrid CNN + LSTM + SVM model for advanced brain tumor classification,” *Netw. Model. Anal. Heal. Informatics Bioinforma.*, vol. 15, no. 1, 2026, doi: 10.1007/s13721-025-00718-8.
- [3] M. F. Tewelgne, S. F. Tewoligne, and T. Z. Yehuala, “Machine learning models for predicting caesarean section delivery among women in Ethiopia,” *Discov. Artif. Intell.*, vol. 6, no. 1, 2026, doi: 10.1007/s44163-026-00925-w.
- [4] C. Kumar, V. Chaganti, U. Samal, and S. K. Singh, “CodeSmellSynergy hybrid ensemble learning framework for detecting python code smells,” *Discov. Comput.*, vol. 29, no. 1, 2026, doi: 10.1007/s10791-026-10055-7.
- [5] M. Najam, H. Khurshid, and F. Akram, “Clustering framework based on random convolutional kernels for segmentation of time-series satellite imagery,” *Int. J. Data Sci. Anal.*, vol. 22, no. 1, 2026, doi: 10.1007/s41060-026-01134-5.
- [6] M. Shafiullah, “Fuzzy k-Means Clustering-Based Machine Learning Models for LFO Damping in Electric Power System Networks,” *C. - Comput. Model. Eng. Sci.*, 2026, doi: 10.32604/cmcs.2026.075269.
- [7] H. Jing, H. Zhang, and N. Wang, “Deep neural mapping unilateral relaxed support vector machines for imbalanced data,” *Discov. Comput.*, vol. 29, no. 1, 2026, doi: 10.1007/s10791-026-10148-3.
- [8] S. P. K. Veeranki *et al.*, “Development and validation of random-forest based federated ensemble learning algorithms for delirium prediction using electronic medical records from eleven hospitals in Austria: a retrospective study,” *BMC Med. Inform. Decis. Mak.*, vol. 26, no. 1, 2026, doi: 10.1186/s12911-025-03322-y.
- [9] S. Deng, M. Sun, L. Duan, and Y. He, “SADD-RFCO: semi-supervised anomalous data detection based on random forest with co-training,” *Knowl. Inf. Syst.*, vol. 68, no. 1, 2026, doi: 10.1007/s10115-026-02694-5.
- [10] B. Wang, “Financial risk identification and prevention system based on random forest algorithm,” *Discov. Artif. Intell.*, vol. 6, no. 1, 2026, doi: 10.1007/s44163-025-00656-4.